

公文字段提取与文件内容审查 API

1. 基本信息

- 服务地址: `https://85af8f.xhang.buaa.edu.cn:52811`
- 请求方式: RESTful HTTP API
- 数据格式: 请求和响应均为 JSON
- 文件传输: 文件内容使用 Base64 编码
- 支持格式: PDF、DOCX、Markdown、TXT

当前服务使用自签名 HTTPS 证书。测试时, `curl` 可使用 `-k`, Python `requests` 可设置 `verify=False`。

2. 文件内容审查

接口

POST `/api/documents/file-guard`

该接口接收文件, 先将文件解析为文本, 再调用内容审查服务。解析正文仅在本次请求期间使用, 不会保存到数据库或持久化上传目录; 请求结束后会清理临时文件。

请求参数

```
{
  "filename": "公文.pdf",
  "content_base64": "文件内容的 Base64 编码"
}
```

字段	必填	类型	说明
filename	是	string	文件名, 必须包含扩展名
content_base64	是	string	文件内容的 Base64 编码

成功响应 (HTTP 200)

```
{
  "filename": "公文.pdf",
  "file_type": "pdf",
  "content_length": 2048,
  "review": {
    "harmful": "false",
    "harmful_type": "normal",
    "harmful_type_label": "正常",
    "harmful_reason": "",
    "harmful_words": "",
    "harmful_degree": "none",
    "harmful_degree_label": "无",
  }
}
```

```
    "confidence": "high",
    "confidence_label": "高",
    "highlight_spans": [],
    "stage": "fragment"
  }
}
```

审查结果字段

字段	类型	说明
harmful	string	false 表示未发现违规，true 表示发现违规
harmful_type	string	违规类型编码
harmful_type_label	string	违规类型名称
harmful_reason	string	审查原因或说明
harmful_words	string	命中的违规词
harmful_degree	string	风险程度编码
harmful_degree_label	string	风险程度名称
confidence	string	置信度编码
confidence_label	string	置信度名称
highlight_spans	array	命中的文本片段
stage	string/null	审查阶段

服务端只返回审查结果，不自动决定是否继续字段提取；调用方根据 review.harmful 自行编排业务流程。

错误响应

HTTP 状态码	说明
400	文件类型不支持或请求参数错误
422	Base64 无效或文件解析失败
502	内容审查服务不可用或返回异常

3. 公文字段提取

接口

```
POST /api/documents/extractions
```

该接口接收文件，解析后提取 11 个标准公文字段。原有字段提取行为保持不变。

请求参数

```
{
  "filename": "公文.pdf",
  "content_base64": "文件内容的 Base64 编码",
  "include_parsed_content": false
}
```

字段	必填	类型	默认值	说明
filename	是	string	—	文件名，必须包含扩展名
content_base64	是	string	—	文件内容的 Base64 编码
include_parsed_content	否	boolean	false	是否在响应中返回解析正文

成功响应 (HTTP 201)

```
{
  "filename": "公文.pdf",
  "file_type": "pdf",
  "content_length": 2048,
  "fields": {
    "文件标题": "关于印发《示例办法》的通知",
    "来文单位": "北京航空航天大学",
    "来文字号": "北航校字（2026）42号",
    "原文日期": "2026-05-26",
    "紧急程度": "",
    "阅文/办文": "阅文",
    "时间节点": "",
    "收文日期": "",
    "关联文件": "",
    "备注": "",
    "是否需明确建议牵头单位": "否"
  },
  "parsed_content": null
}
```

当 `include_parsed_content=true` 时，`parsed_content` 返回解析后的正文；默认不返回。该参数仅用于需要正文的调用场景，内容是否由调用方暂存由调用方自行负责。

字段说明

字段名	说明
文件标题	公文标题全文
来文单位	发文机关或单位名称
来文字号	公文文号
原文日期	公文原始日期

字段名	说明
紧急程度	加急、特急、普通等
阅文/办文	需要阅览还是办理
时间节点	截止时间、完成时限等
收文日期	收文登记日期
关联文件	相关依据或关联文件
备注	补充说明
是否需明确建议牵头单位	是否需要指定主办部门

未识别到的字段返回空字符串，属于正常情况。

错误响应

HTTP 状态码	说明
400	文件类型不支持或请求参数错误
422	文件解析失败
500	服务内部错误

4. Python 调用示例

```
import base64
import requests

base_url = "https://85af8f.xhang.buaa.edu.cn:52811"
file_path = "公文.pdf"

with open(file_path, "rb") as f:
    content_base64 = base64.b64encode(f.read()).decode("ascii")

response = requests.post(
    f"{base_url}/api/documents/file-guard",
    json={
        "filename": file_path,
        "content_base64": content_base64,
    },
    timeout=300,
    verify=False,
)
response.raise_for_status()
print(response.json()["review"])
```

5. 调用建议

- 单个文件建议不超过 50 MB。

- PDF 文件解析可能需要较长时间，客户端超时建议设置为 300 秒或更长。
- 不建议并发提交大量请求。
- 内容审查接口与字段提取接口相互独立；可以先调用 `file-guard`，再根据审查结果决定是否调用 `extractions`。